



Syrian Private University

College Of Engineering

S-L-D

Skin Lesion Detection

اكتشاف الآفات الجلدية باستخدام التعلم العميق

Prepared By

Adam Al-Omayyan

Muhammed AL-Salkhadi

Supervised By

Dr. Kadan Jumaa

مقدمة البحث

يقدم هذا البحث دراسة شاملة لتصنيف آفات الجلد المصطبغة باستخدام تقنيات التعلم العميق، اعتماداً على مجموعة بيانات HAM10000 المدمجة مع ISIC2018 RAW. يهدف المشروع إلى تطوير نموذج شبكة عصبية تلفيفية (CNN) قادر على التمييز بين سبع فئات مختلفة من آفات الجلد، بما في ذلك الميلانوما (Melanoma) وآفات حميدة أخرى، اعتماداً على الصور الجلدية الملتقطة باستخدام تقنية التظير الجلدي (Dermoscopy).

يعتمد النموذج المقترن على معمارية تعلم عميق مدرومة بتقنيات تعزيز البيانات والتعلم بالنقل، وقد تم تقييم أدائه باستخدام مجموعة من المقاييس الإحصائية مثل الدقة، مصفوفة الالتباس، وتقارير التصنيف. كما تم استخدام تقنية Grad-CAM لنفسير قرارات النموذج وتحديد المناطق المؤثرة في عملية التصنيف.

١. الفصل الأول

مقدمة عن المشروع

1.1 تمهيد

يُعد سرطان الجلد من أكثر أنواع السرطانات شيوعاً على مستوى العالم، ويشكل الميلانوما أخطر أنواعه بسبب قدرته العالية على الانتشار والوفاة في حال عدم اكتشافه مبكراً. يعتمد التشخيص التقليدي على الفحص البصري والخبرة الطبية، مما قد يؤدي إلى تفاوت في التشخيص بين الأطباء.

ساهم التطور السريع في مجال الذكاء الاصطناعي، وبشكل خاص التعلم العميق، في توفير أدوات قادرة على تحليل الصور الطبية بدقة عالية، مما يساعد الأطباء في اتخاذ قرارات تشخيصية أكثر دقة وسرعة.

1.1.1 أسباب وأهمية الكشف المبكر

- الارتفاع المستمر في عدد حالات سرطان الجلد عالمياً
- صعوبة التمييز البصري بين بعض الأفات الحميدة والخبيثة
- الحاجة إلى أدوات معاونة تقلل الاعتماد الكامل على التقييم البشري

1.2 بيان المشكلة

تعتمد الطرق التقليدية لتشخيص سرطان الجلد على الخبرة السريرية والفحص اليدوي للصور الجادية، مما يجعلها عرضة للأخطاء والتباين في التقييم. تهدف هذه الدراسة إلى تطوير نظام تصنيف مؤتمت يعتمد على صور dermoscopy لتقديم تشخيص أكثر موضوعية ودقة.

1.3 الأهداف

- تطوير نموذج CNN لتصنيف آفات الجلد باستخدام HAM10000
- دمج بيانات ISIC2018 RAW لتحسين التعميم
- تحقيق دقة عالية ومتوازنة بين الفئات
- تفسير قرارات النموذج باستخدام Grad-CAM

2. الفصل الثاني

الدراسات المرجعية

تمهيد: يقدم هذا الفصل عرضاً وتحليلاً منهجياً للدراسات المرجعية المرتبطة بتصنيف الأمراض الجلدية باستخدام تقنيات التعلم العميق، مع التركيز على مجموعة بيانات HAM10000، وذلك بنفس الترتيب المعتمد في الملف المرجعي.

2.1 الورقة البحثية الأولى:

The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions

Philipp Tschandl, Cliff Rosendahl, Harald Kittel
Scientific Data, 2018
<https://www.nature.com/articles/sdata2018161>

المؤلفون:
المصدر:
الرابط:

المقدمة والخلفية

تعتبر (HAM10000) Human Against Machine with 10000 training images واحدة من أكبر مجموعات بيانات الصور الجلدية متعددة المصادر للأمراض الجلدية الصبغية. وجدت الحاجة لهذه البيانات بسبب العصبية لتشخيص الآف الأمراض الجلدية الصبغية بدقة.

تقنية **Dermatoscopy** تُستخدم لتشخيص الآف الأمراض الجلدية الصبغية بشكل أدق مقارنة بالفحص البصري العادي، وهي مناسبة جدًا لتدريب الشبكات العصبية على تشخيص هذه الأمراض تلقائيًا. الدراسات السابقة، مثل (Binder et al. 1994) أظهرت جدوى استخدام الصور الجلدية لتدريب الشبكات العصبية، لكنها كانت محدودة بسبب قلة عدد العينات ونوعيتها.

الهدف من HAM10000

تهدف HAM10000 إلى توفير مجموعة بيانات تدريبية واسعة ومتعددة لدعم الأبحاث الأكاديمية في مجال الذكاء الاصطناعي لتشخيص الأمراض الجلدية الصبغية، ولتكون مرجعًا لمقارنة أداء الشبكات العصبية مع خبراء الجلد.

البيانات والتصميم

- **الحجم 10015:** صورة جلدية صبغية.
- **المصادر:** تم جمع الصور من موقعين رئيسيين:
 ١. قسم الأمراض الجلدية في جامعة فيينا، النمسا.
 ٢. عيادة سرطان الجلد Cliff Rosendahl ، كوينزلاند، أستراليا.
- **التحقق من التشخيص:** أكثر من 50% من العينات تم التأكيد من تشخيصها عن طريق الفحص النسيجي (Pathology)، بينما استند الباقى إلى متابعة سريرية، توافق الخبراء، أو فحص بالتصوير المجهرى المعاكس (Confocal Microscopy).

طرق المعالجة والتجهيز

١. استخراج البيانات من ملفات **PowerPoint:** استُخدمت مكتبة Python لاستخراج الصور والبيانات الوصفية.
٢. **رقمنة الشرائح الفوتوغرافية القديمة:** تم مسح الشرائح الضوئية القديمة بمسح عالي الدقة، مع تحسين التباين واللون يدوياً.
٣. **فلترة الصور الجلدية:** فصل الصور الجلدية عن الصور السريرية واللقطات القريبة باستخدام نموذج **InceptionV3** مدرب لتصنيف الصور حسب النوع، بدقة 98.68%.
٤. **توحيد التشخيصات النسيجية:** تم دمج المصطلحات المختلفة لتشكيل سبع فئات رئيسية للأمراض الجلدية الصبغية، لتسهيل استخدام البيانات كمرجع للذكاء الاصطناعي والبشر.

الفئات المرضية

الفئات السبع التي يعطيها HAM10000:

١. **akiec:** الأكتينيك كيراتوزيس وسرطان الخلايا الحرشفية داخل البشرة.
٢. **bcc:** سرطان الخلايا القاعدية.
٣. **bkl:** آفات كيراتوزية حميدة شبيهة بالكيراتوز.
٤. **df:** الديرماتوفايروم.
٥. **mel:** الميلانوما.
٦. **nv:** الشامات الميلانينية.
٧. **vasc:** الآفات الوعائية (الأورام الدموية، الأورام الحميرية، النزيف).

التحقق الفني والجودة

- مراجعة يدوية نهائية لاستبعاد الصور غير واضحة أو ذات محتوى يمكن التعرف عليه، أو صور غير صبغية.
- توحيد أبعاد الصور (800x600) بكسل وتعديل التباين واللون يدوياً عند الحاجة.
- توفير كود مخصص على GitHub للطرق المستخدمة في تجهيز وتنظيم البيانات.

التوافر والاستخدام

- HAM10000 متاحة عبر أرشيف ISIC ، مع رخصة CC BY-NC 4.0 للاستخدام الأكاديمي.
- البيانات يمكن الوصول إليها بصور وبيانات وصفية كاملة، بما في ذلك ملاحظات التشخيص والتحقق من الصحة.

الأهمية العلمية

- HAM10000 توفر مجموعة بيانات متنوعة وشاملة لمعظم الأمراض الجلدية الصبغية الشائعة، ما يجعلها معياراً لتدريب وتقدير أنظمة الذكاء الاصطناعي مقارنة بخبرة الأطباء.
- تجاوزت القيود السابقة فيمجموعات البيانات، من حيث التنوع وحجم العينة، مع التركيز على الجودة العالية للصور والتتأكد من صحة التشخيصات.

2.2 الورقة البحثية الثانية

*An insight into racial bias in dermoscopy repositories:
A HAM10000 data set analysis*

Andres Morales-Forero, Lili Rueda Jaime

المؤلفون:

Sebastian Ramiro Gil-Quiñones,

Marlon Y. Barrera Montañez, Samuel Bassetto, Eric Coatanea

JEADV Clinical Practice, 2024

المصدر:

https://onlinelibrary.wiley.com/doi/full/10.1002/jvc2.477?utm_source=chatgpt.com

الرابط:

المقدمة والخلفية

يشير البحث إلى وجود تمثيل ناقص للأفراد ذوي البشرة الداكنة في قواعد البيانات الأكاديمية الخاصة بأمراض الجلد، بما في ذلك مجموعات بيانات الديرماتوسكوبى. هذا النقص يساهم في تفاوت في جودة الرعاية الصحية ويحد من قدرة الأطباء على تشخيص الأمراض الجلدية بدقة لدى هؤلاء الأفراد. تُعرف هذه الظاهرة باسم "التمييز البصري" أو **Visual Racism**، حيث تمثل الصور المستخدمة في التدريب والبحوث الطبية بشكل رئيسي الأفراد ذوي البشرة الفاتحة.

HAM10000 هي واحدة من أكبر مجموعات بيانات الديرماتوسكوبى، وتحتوي على 10,015 صورة من سبع فئات رئيسية للافات الجلدية الصبغية:

- الأكتينيك كيراتوزيس وسرطان الخلايا الحرشفية داخل البشرة (akiec)
- سرطان الخلايا القاعدية (bcc)
- آفات كيراتوزية حميدة شبيهة بالكيراتوز (bkl)
- ديرماتوفايروم (df)
- ميلانوما (mel)
- شامات ميلانينية (nv)
- الآفات الوعائية (vasc)

أهداف الدراسة

تهدف الدراسة إلى:

١. تحليل تمثيل درجات البشرة الداكنة ضمن مجموعة بيانات HAM10000 .
٢. تحديد أي أخطاء أو تحيزات في التوثيق المتعلق بالتنوع العرقي.
٣. مقارنة تمثيل الأمراض الجلدية لدى البشرة الداكنة مقابل ما هو متوفّر في قاعدة البيانات.
٤. تسلیط الضوء على الفجوات والقيود في قدرة البيانات على تدريب خوارزميات الذكاء الاصطناعي بشكل شامل وعادل.

النتائج الرئيسية

١. تمثيل منخفض للبشرة الداكنة:
 - أقل من 5% من الصور تظهر درجات بشرة داكنة، مع احتمال أن بعض العينات الداكنة تمثل ظللاً أو بقعاً على الصورة وليس لون البشرة الفعلي.
٢. تركيز على الأمراض الشائعة في البشرة الفاتحة:
 - معظم البيانات (83.2%) تتركز على الشامات والميلانوما وسرطان الخلايا القاعدية، وهي أكثر شيوعاً في البشرة الفاتحة.
٣. غياب أو نقص تمثيل الأمراض الجلدية الخاصة بالبشرة الداكنة:
 - مثل سرطان الخلايا الحرشفية (SCC) وديرماتوزيس بابولوزا نيجرا (DPN).
 - الميلانوما الوصلية (Acral Lentiginous Melanoma)، الأكثر شيوعاً في الأفراد ذوي البشرة الداكنة، لم تُصنف بشكل كافٍ.
٤. نقص البيانات الوصفية العرقية:
 - لا تحتوي مجموعة البيانات على متغيرات تحدد العرق أو النوع العرقي، مما يعيق القدرة على إجراء تحليلات دقيقة على أساس التنوع العرقي.

منهجية البحث

- تحليل بصري للصور : تم استخدام طريقة **Gray World Algorithm** لتوحيد الألوان وتصحيح تأثيرات الإضاءة على البشرة.
- أخذ عينات من أربعة زوايا لكل صورة لتحديد لون البشرة الأصلي للمريض بشكل دقيق، مع التحقق من 10% من الصور يدوياً بواسطة أطباء الجلد.
- مقارنة الأمراض الممثلة في **HAM10000** مع الأمراض الجلدية الأكثر شيوعاً لدى الأشخاص ذوي البشرة الداكنة وفقاً للأدبيات العلمية.

المناقشة والتفسير

- التحيز في البيانات يؤدي إلى صعوبات في تدريب أنظمة الذكاء الاصطناعي لتشخيص الأمراض الجلدية بشكل عادل، ويزيد من احتمال الخطأ التشخيصي لدى الأفراد ذوي البشرة الداكنة.
- تنوع الشامات والميلانوما في البشرة الداكنة يختلف عن البشرة الفاتحة، ومن دون أمثلة كافية، قد تفشل الخوارزميات في التعرف على الأنماط المرضية بدقة.
- سرطان الخلايا القاعدية يظهر لدى ذوي البشرة الداكنة في مناطق غير معرضة للشمس، وهذا يجعل التشخيص باستخدام معايير البشرة الفاتحة أكثر صعوبة.
- عدم وجود بيانات عن العرق يحد من التفسير والتحقق السريري ويقوض العدالة في التشخيص والبحث.

الاستنتاجات والتوصيات

١. هناك حاجة ملحة لتوسيع تمثيل جميع ألوان البشرة في مجموعات بيانات الديرماتوسكوبى لتفايل التحيزات.
٢. يجب تضمين متغيرات العرق والنوع العرقي لتمكن تحليل أدق للتمييزات المحمولة في التشخيص.
٣. التوسيع لا يعني فقط زيادة عدد الصور للأفراد ذوي البشرة الداكنة، بل أيضًا توفير تنوع مرضي كامل بما يعكس اختلافات ظهور الأمراض الجلدية عبر درجات البشرة.
٤. التمييز البصري في قواعد البيانات الطبية يعيق تطوير أنظمة ذكاء اصطناعي شاملة وعادلة، ويجب معالجة ذلك ضمن تصميم قواعد البيانات والبحوث المستقبلية.
٥. التعاون متعدد التخصصات ضروري لضمان تمثيل وجهات نظر متنوعة ودمجها في تطوير أدوات وبيانات تشخيصية عادلة.

القيمة العلمية

- الدراسة تسلط الضوء على أهمية العدالة التشخيصية في الذكاء الاصطناعي الطبي.
- تقدم نهجاً منهجياً لتقدير التحيز العرقي في مجموعات بيانات الديرماتوسكوبى، مع إمكانية تطبيقه على مجموعات بيانات أخرى.
- تؤكد الحاجة إلى دمج الخبرة البشرية المتنوعة عند إنشاء قواعد بيانات طبية لتجنب تحيزات غير مقصودة.

2.3 الورقة البحثية الثالثة

Multiclass skin lesion classification and localization from dermoscopic images using a novel network-level fused deep architecture and explainable artificial intelligence

المؤلفون: Mehak Arshad, Muhammad Attique Khan,

Nouf Abdullah Almujally, Areej Alasiry,

Mehrez Marzougui, Yunyoung Nam

المصدر: BMC Medical Informatics and Decision Making, 2025

الرابط:

https://bmcmedinformdecismak.biomedcentral.com/articles/10.1186/s12911-025-03051-2?utm_source=chatgpt.com

المقدمة والخلفية

يمثل السرطان الجلدي أحد أكثر أنواع السرطانات شيوعاً في العالم، ويؤثر بشكل كبير على الصحة العامة بسبب معدلات الوفيات العالية عند اكتشافه في مراحل متقدمة. يعتمد التشخيص المبكر على التصوير الديرماتوسكوبى (Dermoscopy)، وهي تقنية غير جراحية توفر صوراً عالية الدقة للجلد، مما يمكن الأطباء من تمييز الأفات الجلدية الصبغية بشكل أكثر دقة.

ومع ذلك، يواجه الأطباء تحديات كبيرة بسبب:

١. تشابه الأنماط بين الأفات المختلفة.
٢. تباين الأحجام والألوان والحواف للافات الجلدية.
٣. غياب الخبرة الكافية لدى بعض الأطباء، مما يقلل من دقة التشخيص اليدوي.

لتجاوز هذه التحديات، ظهرت تقنيات Computer-Aided Diagnostics (CAD)، والتي تعتمد على معالجة الصور والتعلم الآلي لتحسين التشخيص. ومع التطور السريع في تقنيات التعلم العميق (Deep Learning)، أصبح بالإمكان إنشاء نماذج قوية لتصنيف وتحديد موضع الأفات الجلدية بدقة عالية.

أهداف الدراسة

تهدف هذه الدراسة إلى تطوير معمارية تعلم عميق جديدة تعتمد على دمج الشبكات العصبية على مستوى الشبكة (**network-level fusion**)، مع دمج تقنيات الذكاء الاصطناعي القابل للتفسير (Explainable AI) لتصنيف وتحديد موقع الآفات الجلدية ضمن صور الديرماتوسكوبية.

الأهداف المحددة تشمل:

١. تحسين وضوح وتبين الصور لآفات الجلدية قبل التدريب.
٢. تصميم نموذجين عميقين منفصلين (6-block inverted bottleneck & 5-block inverted residual) لاستخراج المعلومات التفصيلية عن الصورة.
٣. دمج النماذج على مستوى الشبكة باستخدام **Depth Concatenation** لتعزيز دقة التصنيف.
٤. استخدام تقنيات الذكاء الاصطناعي القابل للتفسير (LIME) لتحديد مناطق الآفات داخل الصورة.
٥. معالجة مشكلة اختلال توازن الفئات وتحسين الأداء العام للنموذج.

منهجية البحث

١. مجموعات البيانات

تم التحقق من أداء النموذج على مجموعتين رئيسيتين:

- MEL، NV، BCC، AKIEC، DF، BCC، NV: **HAM10000** صورة من سبع فئات رئيسية (VASC، BKL).
- ISIC2018: مجموعة بيانات مشابهة مع تقسيم الصور إلى سبع فئات لاختبار النموذج. تم تقسيم كل مجموعة بنسبة 50% للتدريب و50% لاختبار، مع استخدام تقنيات توسيع البيانات (Augmentation) لتوليد صور جديدة وتوازن الفئات.

٢. تحسين التباهي (Contrast Enhancement)

- تم تطبيق تقنية هجينية تجمع بين **DnCNN** وتقنية **Haze Reduction Deep Denoising Network** لإزالة الضوضاء وتحسين وضوح الآفات دون فقدان التفاصيل الدقيقة للحواف.
- نموذج **DnCNN** يعتمد على شبكة CNN مع طبقات ReLU& Batch Normalization لتقدير الضوضاء في الصورة واستعادة الصورة الأصلية.
- معادلات رياضية دقيقة تم استخدامها لتقدير الضوضاء وتحسين الصورة باستخدام تصحيح Mapping.

3. توسيع البيانات (Data Augmentation)

- لتقليل اختلال توازن الفئات، تم إنشاء صور جديدة عبر:
 - دوران الصورة 90 درجة.
 - الانعكاس الأفقي والرأسي.
- بعد التوسيع، وصل عدد الصور لكل فئة إلى 5,000 صورة، مما رفع إجمالي عدد الصور إلى 35,000 صورة لكل مجموعة بيانات.

4. تصميم النماذج العميقية

5-block Inverted Residual Network (IBR5Net): •

- 101 طبقة عميقية.
- يستخدم **Skip Connections** مع **Parallel Blocks** لاستخراج ميزات منخفضة ومتوسطة المستوى بفعالية.
- يركز على الخصائص الدقيقة لآلاف الجلدية.

6-block Inverted Bottleneck Network (IBR6Net): •

- يركز على استخراج الميزات العميقية والمعقدة.
- يعتمد على عمليات **Convolution** متدرجة وتقنيات توسيع وضغط القنوات لاستخراج معلومات غنية بتكلفة حسابية منخفضة.

5. دمج النماذج (Network-Level Fusion)

- تم دمج النموذجين عبر **Depth Concatenation** بدلاً من دمج الميزات، مما يسمح للنموذج النهائي بالاستفادة من جميع المستويات المكانية والمعلوماتية للصور.

6. التصنيف النهائي

- استخدم النموذج شبكات عصبية ضحلة (Shallow Neural Networks) تحتوي على طبقة أو طبقتين مخفيتين لتصنيف الصور بعد استخراج الميزات العميقية.
- تم تطبيق **Bayesian Optimization** لضبط المعلمات الفائقة للنموذج بدقة عالية.

7. التفسير والذكاء الاصطناعي القابل للتفسير

- استخدم نموذج **LIME** لتحديد مناطق الآفات داخل الصور وتفسير قرارات النموذج، مما يضيف عنصر الثقة والشفافية للنموذج.

النتائج

- بلغت دقة التصنيف على HAM10000 حوالي 91.3% وعلى ISIC2018 حوالي 90.7%.
- تحسنت مقاييس الحساسية (Sensitivity) والدقة (Precision) و الدقة F1-Score & (Precision) بعد التوسعة ومعالجة التباين، حيث وصلت الدقة إلى حوالي 90.91%.
- أظهر نظام LIME قدرة عالية على تحديد موضع الآفات بدقة، ما يعزز قدرة النموذج على التفسير والشفافية.
- مقارنة بالنمذج التقليدية وعمارية Feature-Level Fusion، أظهر نموذج Network-Level Fusion تفوقاً واضحًا في الدقة والأداء مع تكلفة حسابية منخفضة نسبيًا.

الاستنتاجات

١. دمج الشبكات على مستوى الشبكة يسمح باستخراج معلومات شاملة من الصور وتحسين أداء التصنيف مقارنة بالطرق التقليدية.
٢. تحسين التباين وتتوسيع البيانات أساسيا للتعامل مع الصور منخفضة الجودة والفنان غير المتوازنة.
٣. يمكن استخدام هذه العمارة كنظام CAD فعال لتشخيص وتصنيف الآفات الجلدية، مع إمكانية التفسير البصري لمناطق الاهتمام داخل الصورة.
٤. يوصى بالدراسات المستقبلية لتقليل الموارد الحسابية المطلوبة وقصير وقت التدريب، وكذلك اختبار النظام على بيانات أكثر تنوعاً تمثيلاً للفئات العرقية المختلفة.

القيمة العلمية

- يمثل هذا البحث تقدماً كبيراً في تطبيق التعلم العميق على تصنيف وتحديد موقع الآفات الجلدية.
- يوفر إطاراً عملياً لـ CAD Systems مع قابلية تفسير النتائج، ما يعزز الثقة لدى الأطباء.
- يدمج بين التوسيع في البيانات، تحسين التباين، ودمج الشبكات على مستوى الشبكة لتقديم نموذج شامل وفعال.

2.4 الورقة البحثية الرابعة

An Ingeniously Designed Skin Lesion Classification Model Across Clinical and Dermatoscopic Datasets

المؤلفون:

M. S. Rahman, N. Al Mamun, M. Hossain, T. Tazin, A. Al Mahmud, S. M. Uddin

المصدر:

IEEE Access, 2024

الرابط:

<https://pubmed.ncbi.nlm.nih.gov/40870863>

المقدمة والخلفية

ترتكز الدراسة على تطوير نموذج ذكاء اصطناعي متقدم قادر على تصنیف الأفات الجلدية من مصادر متعددة (صور سريرية وديرموسكوبية) بشكل دقيق وسريع. تشير الدراسات السابقة إلى أن معظم النماذج تعتمد على مصدر واحد فقط من الصور، مما يحدّ من قدرتها على التعلم الآلي. لذلك، جاء هذا البحث ليقدم موديلًا هجينًا يجمع بين قوّة الشبكات الالتفافية CNN وقدرات Transformer في فهم السياق البصري، ويهدّف لتجاوز مشكلة عدم توازن الفئات (Class Imbalance) وضعف الأداء في الأنواع النادرة من الأمراض الجلدية.

أهداف الدراسة

تهدف الدراسة إلى:

1. تطوير نموذج جديد **HybridSkinFormer** يجمع بين خصائص Transformer & CNN لمعالجة صور الجلد.
2. تحسين دقة تصنیف أمراض الجلد الشائعة والنادرة من بيانات متعددة المصادر.
3. إدخال دالة تفعيل مبتكرة (**StarPReLU**) لتحسين سرعة ودقة التعلم.
4. معالجة مشكلة الاختلال في توزيع البيانات باستخدام **Enhanced Focal Loss**.
5. توفير تفسير بصري للنتائج باستخدام **Grad-CAM++** لتحديد مناطق الاهتمام في الصورة.

منهجية البحث

- نوع البيانات: دمج صور سريرية وديرموسكوبية من قواعد بيانات متعددة، بعد تنظيفها وتوحيد أبعادها إلى 224×224 بكسل.
- عدد الصور: نحو 18,000 صورة موزعة على 9 فئات مرضية رئيسية.
- تقسيم البيانات: 70% تدريب، 15% اختبار، مع الحفاظ على التوزيع الطيفي (Stratified Split).

► **النموذج المقترن (HybridSkinFormer):** يتكون من أربع مراحل رئيسية:

1. **Feature Extraction Block:** باستخدام بنية شبيهة بـ ResNet لاستخلاص الملامح المكانية الدقيقة.
2. **Multi-Head Attention Encoder:** طبقات Transformer تدمج المعلومات السياقية من كامل الصورة.
3. **Fusion Module:** يدمج الميزات القادمة من الصورتين السريرية والديرموسكوبية.
4. **Classification Head:** طبقات Fully Connected مع دالة Softmax لتحديد نوع الأفة الجلدية.

► **تحسينات المضافة:**

- دالة التفعيل الجديدة **StarPReLU** لتقليل فقدان المعلومات عند القيم السالبة.
- استخدام **Enhanced Focal Loss (EFL)** لمعالجة مشكلة الفئات الفليلة.
- تطبيق **Grad-CAM++** لإظهار المناطق الأكثر تأثيراً في قرار النموذج.

النتائج

حقق النموذج المقترن تفوقاً ملحوظاً على النماذج التقليدية مثل (Swin Transformer) & (EfficientNet-B3) & (ResNet50)

- (Accuracy) 94.2 %
- (Precision) 91.1 %
- (Recall) 91.0 %
- (F1-Score) 91.0 %
- (AUC) 0.97

أظهرت خرائط Grad-CAM++ أن النموذج يركز فعلياً على مناطق الأفة الجلدية وليس على الخلفية أو الظل، مما يؤكد قابلية العالية للتفسير الطبي.

الأهمية العلمية

- يقدم البحث نموذجًا هجينًا فائق الأداء يجمع بين Transformer & CNN لمعالجة بيانات طبية متعددة المصادر.
- يُعد من أوائل النماذج التي تدمج الصور السريرية والديتموسكوبية في تدريب واحد متكامل.
- يطرح ابتكارين رياضيين (StarPReLU) & (EFL) حستنًا دقة التصنيف خصوصًا في الأمراض النادرة.
- يدعم التوجّه الحديث نحو نماذج طبية قابلة للتفسير (Explainable AI) باستخدام Grad-CAM++.

3. الفصل الثالث

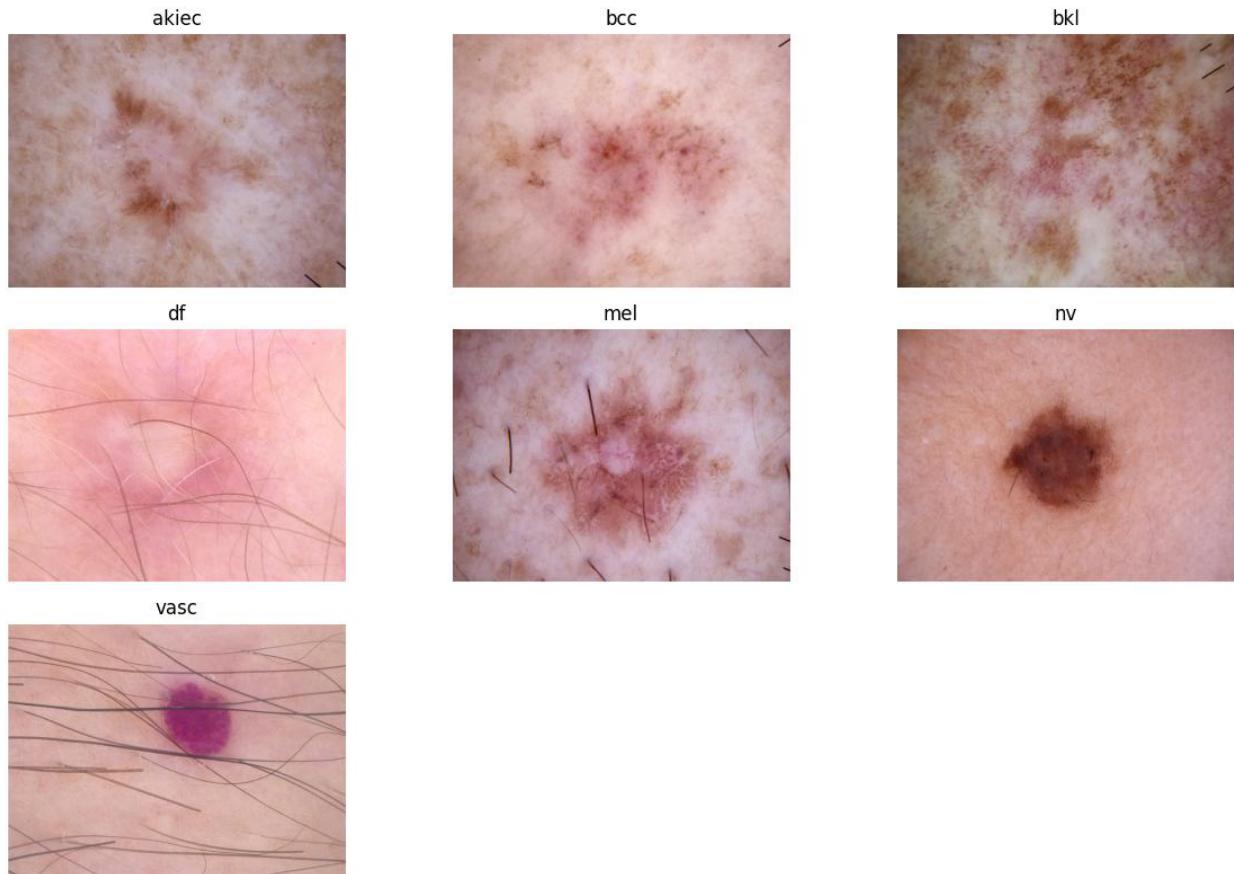
وصف مجموعة البيانات ومعمارية النموذج

3.1 مجموعة البيانات

تم استخدام مجموعة بيانات HAM10000 RAW مع دمج صور إضافية من ISIC2018.

الفئات السبعة:

الفئة (اختصار)	الشرح العربي	ملاحظات
AKIEC	كيراتوزس الأكتينيك	أورام جلدية خبيثة محتملة
BCC	سرطان الخلايا القاعدية	أكثر أنواع سرطان الجلد شيوعاً
BKL	الأفات الحميّدة	حميّدة، قليلة الخطورة
DF	الدرن الدهني	أورام حميّدة
MEL	الميلانوما	خبيثة جدًا، تتطلب تشخيص مبكر
NV	الشامات العاديّة	حميّدة، شائعة
VASC	الأورام الوعائية	أورام دمويّة أو حميّدة



خصائص البيانات:

- صور Dermoscopy عالية الدقة
- بيانات وصفية (العمر، الجنس، موقع الأفة)
- عدم توازن الفئات

3.2 معالجة البيانات

- إعادة تحجيم الصور إلى 224×224
- تطبيق القيم اللونية

- تعزيز البيانات (دوران، انعكاس، تكبير)
- تقسيم البيانات إلى تدريب، تحقق، اختبار

3.3 معمارية النموذج

تم اعتماد نموذج التعلم بالنقل (Transfer Learning) باستخدام شبكة ResNet50، وهي إحدى الشبكات العميقة المعروفة بقدرتها العالية على استخراج الميزات من الصور الطبية، خاصة في مهام التصنيف المعقدة.

ResNet50 تعتمد على مفهوم الوصلات المتبقية (Residual Connections) التي تسمح بتدريب شبكات عميقة جدًا دون الورق في مشكلة تلاشي التدرج (Vanishing Gradient). يتكون النموذج من 50 طبقة عميقة موزعة على كتل تلافيفية متتالية.

في هذا المشروع، تم استخدام نموذج ResNet50 مدرب مسبقاً على مجموعة بيانات ImageNet، ثم إعادة تكييفه (Fine-Tuning) ليتناسب مع مهمة تصنيف آفات الجلد في مجموعة HAM10000.

تعديلات المعمارية:

- الإبقاء على الطبقات التلافيفية الأساسية للنموذج لاستخراج الميزات.
- استبدال طبقة الإخراج الأصلية بطبقة Fully Connected جديدة بعدد 7 نيوترونات تمثل الفئات السبع لمجموعة HAM10000.
- استخدام دالة Softmax في طبقة الإخراج لإعطاء احتمالات الانتماء لكل فئة.

4. الفصل الرابع

عملية التدريب وتقدير النموذج

4.1 معلمات التدريب

- Loss Function: Cross-Entropy •
- Optimizer: Adam •
- Learning Rate: 0.0001 •
- Epochs: 30 •
- Device: GPU(RTX4060) •

4.2 نتائج التدريب

أظهر النموذج تحسناً تدريجياً في دقة التدريب والتحقق، مع استقرار ملحوظ بعد عدد معين من العصور التدريبية.

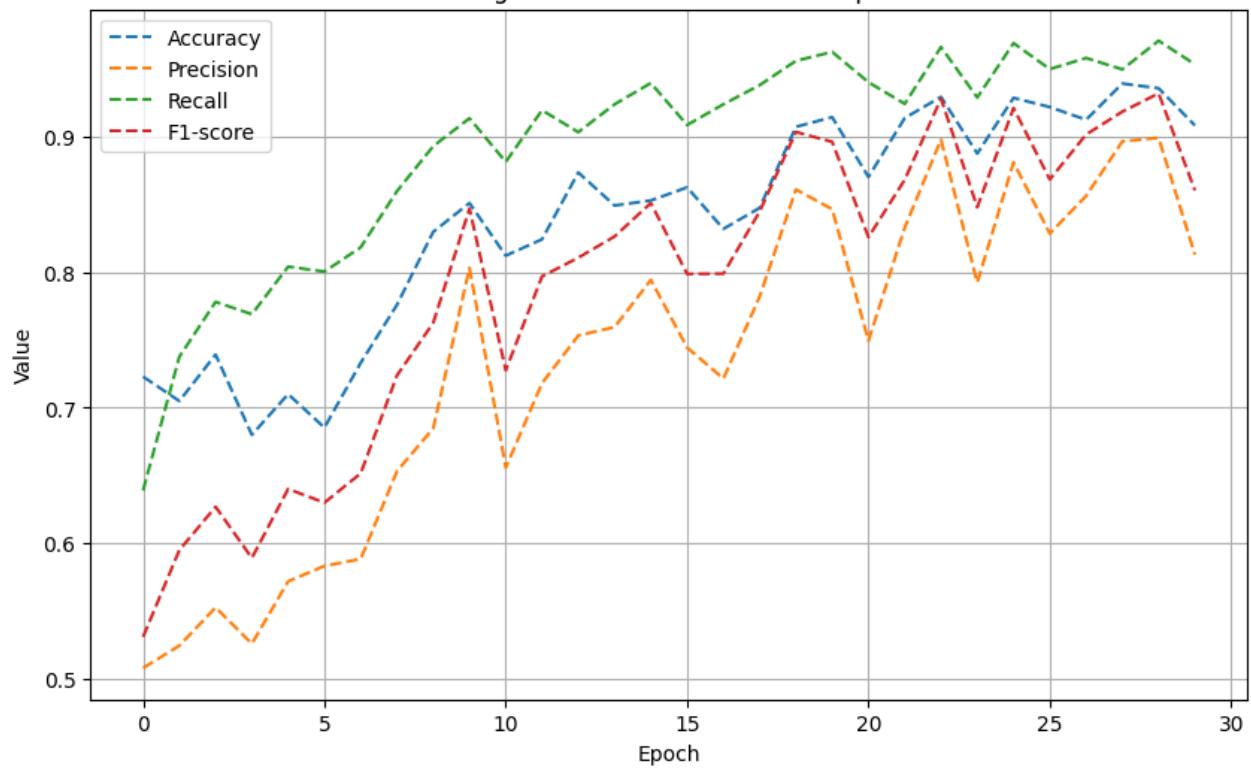
4.3 أداء الاختبار

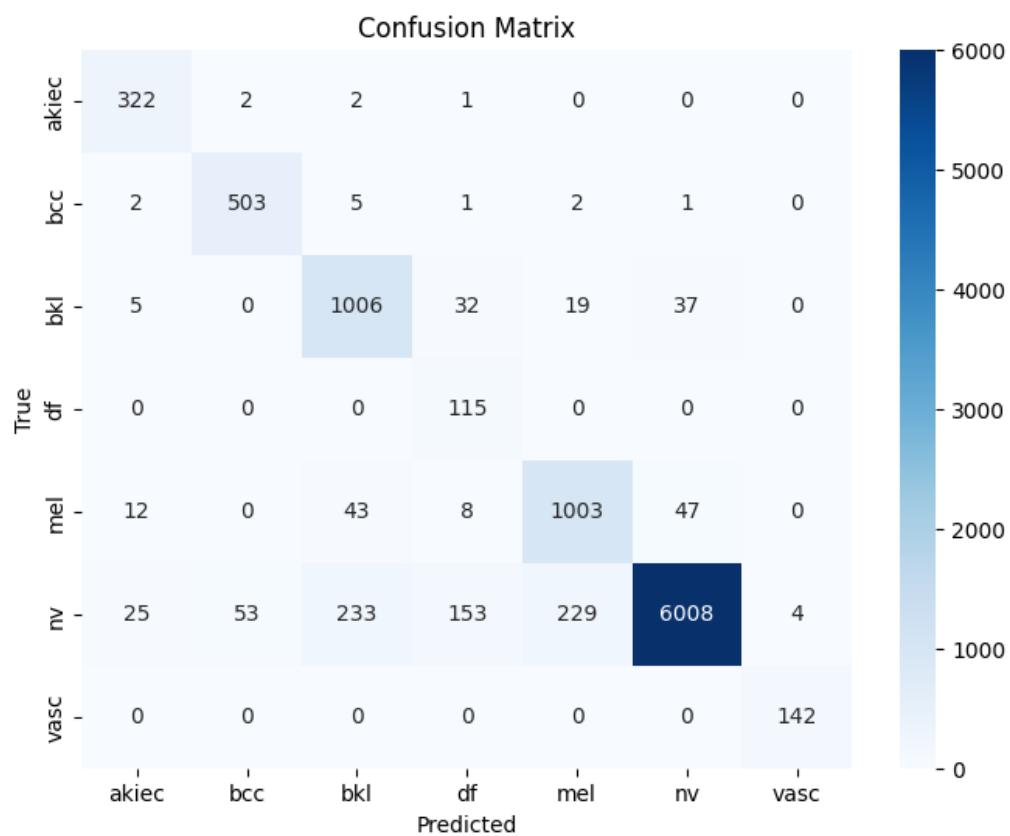
تم تقييم نموذج ResNet50 على كامل مجموعة بيانات HAM10000 المكونة من 10,015 صورة، وحقق النموذج دقة إجمالية (Accuracy) بلغت 91%， مما يدل على أداء قوي وموثوق في مهمة التصنيف متعدد الفئات.

يوضح تقرير التصنيف النتائج التفصيلية لكل فئة:

	precision	recall	f1-score	support
akiec	0.88	0.98	0.93	327
bcc	0.90	0.98	0.94	514
bkl	0.78	0.92	0.84	1099
df	0.37	1.00	0.54	115
mel	0.80	0.90	0.85	1113
nv	0.99	0.90	0.94	6705
vasc	0.97	1.00	0.99	142
accuracy			0.91	10015
macro avg	0.81	0.95	0.86	10015
weighted avg	0.93	0.91	0.91	10015

Training & Validation Metrics Over Epochs





تشير النتائج إلى تفوق النموذج في تصنیف الفئات الشائعة مثل (nv) و(bcc)، في حين يظهر انخفاض نسبي في دقة فئة (df) نتيجة عدم توازن البيانات وقلة عدد العينات.

بلغ المتوسط الموزون (Weighted Average) لمقياس F1-score قيمة 0.91، بينما بلغ المتوسط الكلي (Macro Average) قيمة 0.86، مما يعكس أداءً متوازناً نسبياً عبر مختلف الفئات.

5. الفصل الخامس

تفسير النموذج باستخدام Grad-CAM

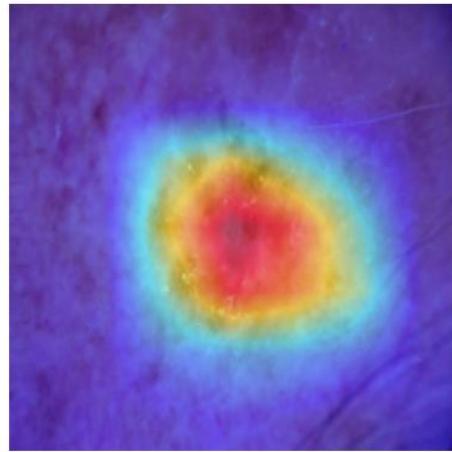
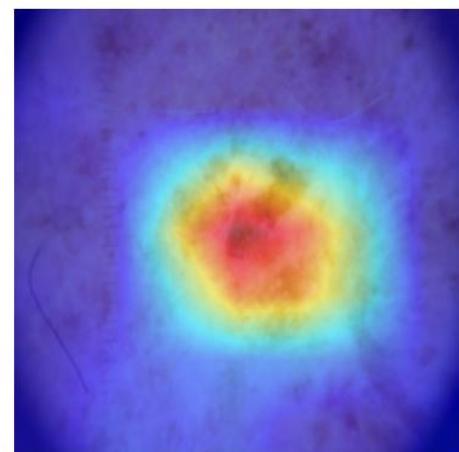
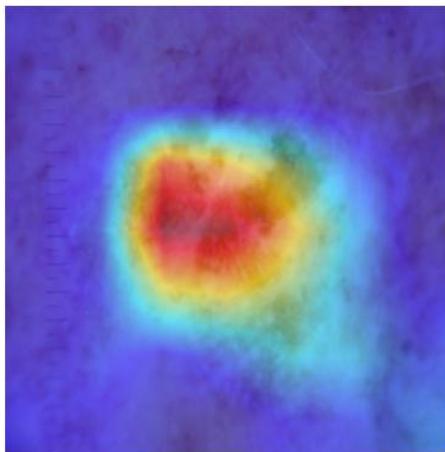
تم تطبيق تقنية Grad-CAM لتحديد المناطق التي يعتمد عليها النموذج في التصنيف، حيث أظهرت النتائج تركيز النموذج على مناطق الأفة الجلدية بشكل يتوافق مع الممارسات السريرية.

نقاط القوة:

- قابلية التفسير
- أداء جيد على بيانات حقيقية

القيود:

- عدم توازن الفئات
- الحاجة لبيانات أكثر لفئة الميلانوما



الخاتمة

أظهر النموذج المقترن قدرة واعدة على تصنیف آفات الجلد باستخدام بيانات HAM10000 و ISIC2018. يمكن لهذا النظم أن يشكل أداة مساعدة فعالة لأطباء الجلدية في الكشف المبكر عن سرطان الجلد.